

KCH-MedRank：面向循证检索增强生成的可解释医学证据控制层

匿名作者

2026 年 5 月 21 日

摘要

医学检索增强生成系统在答案生成之前需要准确、具有医学依据且可检查的证据选择能力。本文提出 KCH-MedRank：一种可解释医学证据控制层，其实现形式是可复现、知识约束的局部超图学习排序框架，用于生物医学证据检索与重排序。增强候选生成提高 top-100 证据召回上限，KCH-MedRank 在 BioASQ 留出测试集上相对于强 Hybrid RRF 提升 top-10 证据检索效果。相对于同一候选池上的真实 MedCPT Cross-Encoder 基线，KCH-MedRank 的 Recall@10 提升达到统计显著，而 MRR@10 与 nDCG@10 为正向但未显著的趋势。PubMedQA Qwen3-8B pilot 表明，在受控下游生成闭环中，更好的证据选择可以提升答案准确率和 Macro-F1，但所有比较证据来源的引用支持率都已较高。结果将 KCH-MedRank 定位为 medical RAG 的白盒证据选择模块，而不是临床决策系统。

1 引言

循证医学问答要求系统在生成或选择答案之前检索到相关的生物医学证据。检索增强生成 (RAG) 为结合检索证据与语言模型提供了通用框架 [8]，近期医学 RAG 基准研究也表明，检索组件选择会显著影响医学问答效果 [15]。然而，常规词法检索或稠密检索通常只建模问题与段落之间的成对相似度。生物医学证据常常由问题、段落、MeSH 概念、生物医学实体、文档和关系来源之间的高阶关系共同组织。

本文研究的是一个实践性、领域特定的证据控制层，而不是新的通用 RAG 范式。我们提出 KCH-MedRank：一种知识约束的局部超图学习排序框架，可作为生物医学 RAG 的白盒证据选择模块。该方法使用 BM25、稠密检索和倒数排名融合保持候选生成的可复现性 [2, 11]，随后围绕每个问题及其候选证据段落构建局部跨粒度超图。

本文贡献是一个聚焦且可解释的证据重排序框架。KCH-MedRank 结合生物医学语义重排序分数、MeSH 层级感知特征、局部超图扩散与中心性特征，以及查询分组 LambdaMART 排序，以提升证据检索效果并暴露重排序所使用的证据信号。超图信号作为可解释排序特征使用，而不是作为手工调权的独立公式。该系统不声称替代临床判断，不提供临床诊断，也不保证答案绝对正确。

实验使用公开生物医学问答资源，并强调证据检索指标、消融实验和受控支持分析。在 BioASQ 证据检索设置中，增强候选生成提高了留出测试集 top-100 召回上限，KCH-MedRank 相对于原始

Hybrid RRF 和真实 MedCPT Cross-Encoder 基线提升了 top-10 证据检索效果。PubMedQA 被用作次要诊断设置：检索实验检验证据覆盖的迁移性，固定 prompt 的 Qwen3-8B pilot 检查证据选择是否影响下游答案准确率和支持行为。

本文贡献包括：

- 构建可复现的两阶段生物学证据检索流水线，包含 BM25、稠密检索、Hybrid RRF、增强候选融合和留出测试评估；
- 设计局部知识约束超图表示，连接问题、段落、文档、实体、MeSH 概念、层级结构和辅助关系信号；
- 在查询分组条件下训练学习排序重排序器，联合利用检索、生物学语义、MeSH 层级、实体、关系和超图特征；
- 进行面向证据的评估，包括 Recall@k、Hit@k、MRR@k、nDCG@k、困难重排序子集、配对 bootstrap 显著性检验、消融实验、失败分析和受控 PubMedQA Qwen3-8B 生成 pilot。

失败分析也显示存在丢失的金标准证据，因此本文将该方法表述为具有明确净收益和清晰失败模式的证据检索改进，而不是临床医学问答的完整解决方案。

2 相关工作

2.1 医学检索增强问答

医学 RAG 基准研究使语料、检索器和主干模型的系统评估更加清晰。MedRAG/MIRAGE 基准在多个医学问答数据集上评估医学 RAG 配置，并指出检索设置对下游医学问答具有较大影响 [15]。迭代式医学 RAG 进一步通过为复杂问题生成后续检索查询来扩展这一方向 [16]。本文范围更窄，重点放在证据检索与重排序上，而不是过早提出强生成结论。

2.2 生物医学问答数据集与检索

BioASQ 是长期运行的生物学语义索引与问答基准 [12]，BioASQ-QA 提供人工整理的问题、参考答案、文档、片段和概念，适合生物医学问答研究 [7]。PubMedQA 是互补的生物学研究问题回答数据集，围绕 PubMed 摘要提供 yes/no/maybe 标签 [4]。在生物学语义检索方面，MedCPT 使用大规模 PubMed 搜索日志训练生物学检索器与重排序器 [5]。

2.3 图与超图 RAG

GraphRAG 类方法使用图结构组织检索信息，其中 local-to-global search 被用于面向查询的摘要任务 [3]。Medical Graph RAG 将用户文档、可信医学来源和受控词表连接起来，以支持医学回答的证据 grounding [14]。HyperGraphRAG 认为超边可以表示普通成对图边无法直接表达的 n 元关系 [9]，跨粒度 HGRAG 则在不同检索粒度上建模实体和段落 [13]。近期 Medical HyperRAG




图 1: KCH-MedRank 方法概览。该方法先构建高召回候选池，再围绕每个问题和候选集合构建知识约束局部超图，并将超图特征与生物医学语义特征用于查询分组学习排序。

预印本研究了以患者为中心的临床问答，通过 ClinBridge 超图组织病历、病例和指南 [17]。KCH-MedRank 继承高阶关系建模动机，但研究范围不同：本文使用公开生物医学问答资源，避免依赖私有临床记录，并评估局部证据重排序模块，而不是完整的患者中心临床决策支持框架。

2.4 受控生物医学知识

MeSH 是由美国国家医学图书馆维护的受控且层级化的词表，用于生物医学和健康信息的索引、编目与检索 [10]。PrimeKG 融合了疾病、蛋白、药物、表型等生物医学实体之间的多模态精准医学关系 [1]。在本文中，MeSH 层级特征是医学约束设计的核心，而 PrimeKG 由于精确名称匹配覆盖稀疏，仅作为辅助关系来源。

3 任务定义

给定医学问题 q 、生物医学语料库 C 以及可选知识源 K ，系统返回排序后的证据列表 E ，并可选返回答案 a 。主要任务是证据检索与重排序；答案生成是次要任务。

对于每个问题，第一阶段检索器从 C 中返回候选池 $D_q = \{d_1, \dots, d_M\}$ 。重排序器随后利用检索分数、生物医学语义分数、概念与实体特征，以及局部超图特征，对 D_q 估计改进排序。评估重点包括 $\text{Recall}@k$ 、 $\text{MRR}@k$ 、 $\text{nDCG}@k$ 和 evidence coverage 。

形式化输出为：

$$(a, E, P),$$

其中 a 在证据检索为主的设置中是可选项， E 是排序后的支持证据列表， P 是用于案例分析的可解释实体、概念或超图路径。

4 方法

4.1 第一阶段检索

第一阶段在任何知识感知重排序之前先构建高召回候选池。我们使用 BM25 作为词法基线，稠密检索作为语义基线，并使用倒数排名融合 (RRF) 作为默认混合检索器。对于检索来源 s ，记段落 d 对问题 q 的排名为 $r_s(q, d)$ ，融合分数为：

$$\text{RRF}(q, d) = \sum_{s \in S} \frac{w_s}{k + r_s(q, d)},$$

其中 S 是检索来源集合， w_s 是来源权重，所报告实验中 $k = 60$ 。原始 Hybrid RRF 使用等权 BM25 和稠密检索。

增强候选生成路径的目标是提高重排序所需的 top-100 召回上限。该路径加入基于标题、正文和 MeSH 扩展字段的 fielded BM25，并加入 MedCPT dual-encoder 稠密检索作为额外生物学语义来源。融合权重仅在验证集上选择。被选中的 w122 设置赋予 BM25 和稠密检索权重 1.0、fielded BM25 权重 1.2、MedCPT dual-encoder 权重 0.2。该设置根据验证集 Recall@100 选择，而不是根据测试集表现选择，因为重排序只能改善已经进入候选池的证据段落。

4.2 知识约束局部超图

对于每个问题及其 top- M 候选，KCH-MedRank 构建局部超图 $H_q = (V_q, \mathcal{E}_q)$ 。节点集合包括问题节点、候选段落节点、文档节点、生物学实体节点、MeSH 概念节点、可选 MeSH 树节点和可选关系节点。超边可以同时连接多个节点，因此能够表示普通成对相似度不易捕捉的高阶关系。

主要超边类型包括 question-entity、question-MeSH、question-passage candidate、passage-entity、passage-document、document-MeSH、shared-entity passages、entity-type concept、MeSH hierarchy，以及辅助 PrimeKG 关系边。用于消融的成对图变体和无医学知识超图变体来自同一候选池：成对图变体将多节点超边拆解为以锚点为中心的成对边，无医学知识变体只保留候选结构和排名分组结构。

局部设计避免在数百万生物学段落上构建全局图。同时，该设计保持方法可解释：特征分析和案例研究可以报告哪些概念重叠、层级链接、共享候选簇或超图中心性信号影响了重排序。

4.3 超图扩散与结构特征

KCH-MedRank 将超图扩散作为可解释特征，而不是作为独立的重排序公式。种子分布在问题节点、问题实体节点和问题 MeSH 节点上赋予初始质量。每次迭代通过加权超边传播分数：

$$x^{(t+1)} = (1 - \alpha)x^{(0)} + \alpha \cdot \text{Propagate}(x^{(t)}, \mathcal{E}_q),$$

其中 $\alpha = 0.85$ ，实现使用三轮扩散。段落级扩散分数随后在每个问题的候选集合内进行 min-max 归一化。我们还计算加权重中心性、局部节点数、局部超边数、共享实体边数、文档-MeSH 边数以及可选层级边数。

算法 1: KCH-MedRank 局部证据控制与重排序

1. **候选检索。**对问题 q , 从 BM25、稠密检索、fielded BM25 和 MedCPT dual-encoder 来源检索 top- M 段落, 并使用验证集选择的加权 RRF 融合。
2. **局部超图构建。**为 q 、候选段落、文档、抽取的生物学实体、MeSH 描述符、MeSH 层级概念和可选关系端点创建节点。加入 query-concept、passage-concept、document-MeSH、共享概念候选簇、层级链接、候选成员关系和辅助 PrimeKG 关系超边。
3. **超边加权与归一化。**根据来源可靠性和局部证据强度设置边权: 候选成员边使用归一化 RRF 分数, 实体和 MeSH 边使用归一化重叠/覆盖, 层级边使用树距离倒数, 关系边因精确名称覆盖稀疏而降低权重。每个局部图内部在传播前对关联边权进行归一化。
4. **扩散传播。**在问题节点、问题实体节点和问题 MeSH 节点初始化质量。以 $\alpha = 0.85$ 运行三轮带重启扩散, 并在候选集合内归一化段落扩散分数。
5. **段落特征抽取。**对每个段落拼接检索分数与排名、生物学语义分数、实体重叠、MeSH 精确与层级特征、辅助关系特征、扩散分数、中心性和局部图计数特征。
6. **查询分组 LambdaMART 打分。**在验证集模型选择后, 使用每个问题作为一个 group 训练 LightGBM LambdaMART 排序器, 并在测试候选上打分排序得到最终证据列表。

图 2: 局部超图构建、归一化、扩散、特征抽取和查询分组学习排序的紧凑伪代码。

4.4 生物学知识特征

重排序器使用若干具有医学动机的特征组。实体特征包括实体重叠数量、实体 Jaccard 相似度、问题实体覆盖率和段落实体数量。精确 MeSH 特征包括 MeSH 重叠、MeSH Jaccard 相似度、问题 MeSH 覆盖率和段落 MeSH 数量。层级感知 MeSH 特征包括精确描述符重叠、父级匹配、祖先匹配、兄弟节点匹配、树距离相似度、查询概念覆盖、段落层级覆盖、段落概念特异性, 以及基于 MeSH 术语或父级概念的共享候选簇。

PrimeKG 派生特征仅作为辅助关系信号, 包括关系数量、问题关系覆盖率和局部关系边数量。由于精确名称关系覆盖较稀疏, 这些特征不被视为主要提升来源。

4.5 学习排序

主监督重排序器采用查询分组学习排序模型, 即使用 LambdaMART 风格目标训练的 LightGBM 梯度提升树排序器 [6]。每个问题构成一个排序组, 候选段落构成样本行, 二值相关性标签来自金标准证据标注。特征向量结合检索分数、生物学语义分数、实体特征、精确与层级感知 MeSH 特征、辅助关系特征和局部超图结构特征。

超参数在验证集上选择。报告实验的搜索空间为叶子数 {15, 31}、学习率 {0.03, 0.05}、估计器数量 {80, 160}, 以及 blend weight {0, 0.1, 0.2, 0.35}; blend weight 用于在模型分数和原始候选排

表 1: 增强 BioASQ 实验中 KCH-MedRank 的主要特征重要性。

特征	重要性
生物医学语义分数	505
Hybrid 分数	416
Dense 分数	376
BM25 排名分数	349
生物医学语义排名分数	304
段落实体数量	246
Dense 排名分数	242
BM25 分数	215
共享 MeSH 术语簇大小	197
共享 MeSH 父级簇大小	174
超图度中心性	149
段落 MeSH 特异性	135
超图扩散分数	130

名分数之间插值。选择准则优先考虑验证集 MRR@10，其次是 Recall@10 和 nDCG@10。完成验证选择后，最终模型在训练集加验证集上重新训练，并只在留出测试集上评估一次。

表 1 的特征重要性显示，语义信号和第一阶段检索信号仍然处于核心位置，同时 MeSH 共享簇、段落概念特异性和超图中心性特征提供了可解释的生物医学与结构信息。这支持一个谨慎结论：KCH-MedRank 的重排序提升来自检索强度、生物医学语义和局部知识约束结构的结合，而不是依赖单一知识源。

5 实验设置

5.1 数据集

主数据集为 `rag-datasets/rag-mini-bioasq`，作为紧凑的 BioASQ 风格生物医学证据检索设置。完整处理后数据包含 4,719 个问题。我们使用基于问题标识符桶的确定性问题级划分：除验证和测试桶外的问题用于训练，模 5 后余数为 3 的问题用于验证，余数为 4 的问题用于测试。在增强 BioASQ 实验中，训练集包含 2,832 个问题，验证集包含 944 个问题，留出测试集包含 943 个问题。该划分在模型选择之前固定。

每个问题对应一组金标准证据段落标识符。评估在段落级别进行。重排序器只能接收第一阶段检索池返回的候选，因此候选生成器的 Recall@100 被报告为召回上限分析。划分在问题级完成，测试问题中的段落不会作为重排序器的正例训练标签使用。PubMedQA 用作次要诊断数据集，而不是主结果来源。

5.2 基线

我们同时比较第一阶段检索基线和重排序基线。第一阶段基线包括 BM25、稠密生物学检索、原始 Hybrid BM25 + dense RRF、带 MeSH 扩展的 fielded BM25、MedCPT dual-encoder 检索和增强 Hybrid RRF。增强 Hybrid RRF 不在测试集上调参；其 w122 权重由验证集 Recall@100 选择。

重排序基线包括同一增强候选池上的 MedCPT Cross-Encoder、仅检索特征的 LambdaMART、带生物学语义特征但不含超图特征的 LambdaMART、成对图学习排序、不含医学知识的超图学习排序，以及完整 KCH-MedRank。我们还报告移除单个特征组的消融实验，包括移除生物学语义分数、MeSH 层级特征、生物学实体特征、超图扩散与中心性，以及 PrimeKG 关系特征。

5.3 评估

主要检索指标包括 Recall@ k 、Hit@ k 、MRR@ k 、nDCG@ k 和 evidence coverage，其中 $k \in \{1, 3, 5, 10, 20, 50, 100\}$ 。当一个问题有多个金标准证据段落时，Recall@ k 定义为 macro evidence coverage：先计算每个问题 top k 中命中的金标准段落占该问题全部金标准段落的比例，再对问题取平均。Hit@ k 是查询级成功指标：top k 中至少出现一个金标准段落则为 1，否则为 0。MRR@ k 也是查询级指标：取 top k 内首个金标准段落排名的倒数；若无命中则为 0。nDCG@ k 使用 qrel 相关性作为 gain；由于当前证据标签为二值，实际为二值 gain 的 DCG，并以截至 k 的理想金标准排序归一化。Evidence coverage 与 Recall@ k 数值相同，用于强调医学证据 grounding 的覆盖解释。

统计检验采用基于留出测试问题的成对 bootstrap，使用 10,000 次重采样和固定随机种子。我们报告相对于原始或增强 Hybrid RRF 以及可用时相对于真实 MedCPT Cross-Encoder 基线的置信区间和双侧 p 值。困难重排序子集仅用于诊断：该子集包含 Hybrid top-100 中存在至少一个金标准段落但 Hybrid top-10 未命中任何金标准段落的测试问题。该子集不替代完整留出测试集评估。

5.4 验证集选择

表 2 报告增强候选生成的验证集选择结果。被选中的 w122 设置以 BM25 和稠密检索为基础来源，以 fielded BM25 作为更强召回来源，并加入 MedCPT dual-encoder 检索作为额外生物学语义来源。该设置因最大化验证集 Recall@100 而被选择，符合重排序阶段提升候选上限的目标。

完整候选融合搜索空间包括 BM25、dense、fielded BM25 与 MedCPT dual encoder 权重分别为 (1.0, 1.0, 0.0, 0.0) 的原始 Hybrid 设置，以及 w052 (1.0, 1.0, 0.5, 0.2)、w084 (1.0, 1.0, 0.8, 0.4)、w102 (1.0, 1.0, 1.0, 0.2) 和 w122 (1.0, 1.0, 1.2, 0.2)。这些设置只根据验证集 Recall@100 选择；留出测试集仅在选择完成后评估。LambdaMART 超参数搜索空间在第 4 节给出，模型选择同样只使用验证集。

5.5 下游生成 Pilot

为连接证据选择与 medical RAG 设置，本文使用 DashScope OpenAI-compatible Qwen3-8B 端点运行受控 PubMedQA pilot。评估使用 100 个 PubMedQA 问题，来自 Hybrid RRF、当前可

表 2: 验证集选择的增强候选生成设置, 融合权重仅在验证集上选择。

融合设置	BM25	Dense	Fielded BM25	MedCPT DE	验证 R@100	测试 R@100
Original Hybrid	1.0	1.0	0.0	0.0	0.6325	0.6077
w052	1.0	1.0	0.5	0.2	0.6391	0.6163
w084	1.0	1.0	0.8	0.4	0.7329	0.7084
w102	1.0	1.0	1.0	0.2	0.7529	0.7285
w122, selected	1.0	1.0	1.2	0.2	0.7568	0.7388

表 3: 增强候选池上的 BioASQ 留出测试证据检索结果。

方法	Recall@10	MRR@10	nDCG@10	Recall@100
原始 Hybrid RRF	0.4636	0.7550	0.5848	0.6077
增强 Hybrid w122	0.4660	0.7530	0.5844	0.7388
MedCPT Cross-Encoder	0.5172	0.7775	0.6390	0.7388
增强 KCH-MedRank	0.5332	0.7882	0.6446	0.7388

用 PubMedQA 语义 cross-encoder 输出和 KCH 风格超图重排序输出共同覆盖的问题集合。每个条件使用相同 top-5 证据段落、相同 prompt 模板、temperature 0、最多 256 个输出 token, 且不进行微调。模型必须返回 yes、no 或 maybe 之一, 并给出段落引用。本文报告 Accuracy、Macro-F1、引用支持率、无支持声明率和答案-证据实体一致性。该实验是 pilot 诊断, 不替代 BioASQ 检索评估。

6 实验结果

6.1 候选池质量

表 3 总结了 BioASQ 留出测试集主结果。原始 Hybrid RRF 测试基线的 Recall@10 为 0.4636, MRR@10 为 0.7550, nDCG@10 为 0.5848, Recall@100 为 0.6077。增强 w122 候选池根据验证集 Recall@100 选择, 并在测试集达到 Recall@100 = 0.7388, 为重排序提供了更强的候选上限。这一步很重要, 因为如果金标准证据没有进入候选池, 后续重排序无法恢复该证据。

6.2 留出测试集主结果

Enhanced KCH-MedRank 达到 Recall@10 = 0.5332、MRR@10 = 0.7882、nDCG@10 = 0.6446、Recall@100 = 0.7388。相对于原始 Hybrid RRF, 这对应 Recall@10 +0.0696、MRR@10 +0.0332、nDCG@10 +0.0598 的提升。相对于增强 Hybrid RRF 的候选排序, KCH-MedRank 的 Recall@10 提升 +0.0673, MRR@10 提升 +0.0352, nDCG@10 提升 +0.0602, evidence coverage@10 提升 +0.0673。

表 4: BioASQ 留出测试集上增强 KCH-MedRank 与增强 Hybrid RRF 的成对 bootstrap 比较。

指标	Hybrid RRF	KCH-MedRank	95% CI	p 值
Recall@10	0.4660	0.5332	[+0.0546, +0.0804]	0.0002
MRR@10	0.7530	0.7882	[+0.0224, +0.0481]	0.0002
nDCG@10	0.5844	0.6446	[+0.0509, +0.0701]	0.0002
Evidence coverage@10	0.4660	0.5332	[+0.0550, +0.0805]	0.0002

表 5: 同一增强候选池上增强 KCH-MedRank 与 MedCPT Cross-Encoder 的成对 bootstrap 比较。

指标	基线	KCH-MedRank	差值	p 值
Recall@10	0.5172	0.5332	+0.0160	0.0074
MRR@10	0.7775	0.7882	+0.0107	0.1384
nDCG@10	0.6390	0.6446	+0.0056	0.2668

表 4 报告了相对于增强 Hybrid RRF 的成对 bootstrap 检验。四个 top-10 指标均达到显著, $p = 0.0002$ 。这说明提升并不只是来自更强候选池, 重排序步骤本身也显著改变了 top-10 证据排序。

6.3 与生物医学语义重排序的比较

在同一增强候选池上, 真实 MedCPT Cross-Encoder 基线达到 Recall@10 = 0.5172、MRR@10 = 0.7775、nDCG@10 = 0.6390。表 5 报告了相对于该强语义基线的成对 bootstrap 结果。KCH-MedRank 在 Recall@10 上显著提升 ($p = 0.0074$), MRR@10 和 nDCG@10 为正向提升但未达到统计显著。

与 MedCPT Cross-Encoder 的比较是对所提出重排序器更严格的检验。结果表明, KCH-MedRank 能在强生物医学语义重排序器之外进一步提高 top-10 证据覆盖, 但 MRR 和 nDCG 的排序敏感指标只能表述为正向趋势, 而不是显著提升。这些结果支持本文的证据检索主张, 但尚不足以把答案生成作为主要贡献。

6.4 Hard Reranking 与 PubMedQA 诊断

表 6 报告了 hard subset 诊断结果。该子集包含增强 Hybrid top-100 中存在金标准证据、但增强 Hybrid top-10 未命中的 BioASQ 留出测试问题, 共 65 个问题。该子集只用于诊断分析, 不能替代完整测试集评估。在该子集上, 增强 Hybrid RRF 的 Recall@10 按定义为 0, 而完整 KCH-MedRank 达到 Recall@10 = 0.4751。这说明当候选池中存在可恢复金标准证据时, 重排序器能够将相当一部分遗漏证据提升到 top-10。该子集也再次显示了消融中的整体趋势: 检索和语义特征解释了很大一部分恢复效果, 超图和医学知识特征更应解释为互补信号, 而不是单独解释全部提升。

表 7 给出了 PubMedQA 上的次要检索诊断。PubMedQA 的证据结构与 BioASQ 不同, 且一位命中表现已经很强, 因此本文仅将其作为稳健性检查。轻量 HGB 知识重排序器相对于其 Hybrid RRF 来源将 Recall@10 从 0.8200 提高到 0.8953; 实验日志中的成对 bootstrap 显示 Recall@10 差

表 6: BioASQ 留出测试集 hard reranking 子集诊断: 增强 Hybrid top-100 含有金标准证据, 但增强 Hybrid top-10 未命中。

方法	Recall@10	MRR@10	nDCG@10	Recall@100
增强 Hybrid RRF	0.0000	0.0000	0.0000	0.8375
仅检索特征 LambdaMART	0.4411	0.2180	0.2424	0.8375
LambdaMART + 语义、无超图	0.4550	0.2821	0.2907	0.8375
成对图 LTR	0.4415	0.2755	0.2768	0.8375
完整 KCH-MedRank	0.4751	0.2742	0.2896	0.8375

表 7: PubMedQA 留出测试集上的次要检索诊断。HGB 知识重排序器是 Hybrid 候选池上的轻量稳健性重排序器, 并非 BioASQ 主实验中的完整增强 KCH-MedRank 配置。

方法	Recall@10	MRR@10	nDCG@10	Recall@100
BM25	0.7284	0.9510	0.7490	0.8526
Dense	0.8644	0.9863	0.8760	0.9425
Hybrid RRF	0.8200	0.9850	0.8369	0.9350
Cross-encoder 重排序	0.8268	0.9806	0.8381	0.9410
HGB 知识重排序器	0.8953	0.9861	0.9021	0.9350

值为 +0.0754, $p = 0.0002$ 。MRR@10 仅从 0.9850 变化到 0.9861, 且不显著, 这与 PubMedQA 已经具有较高一位命中的特点一致。因此, 该结果支持证据覆盖改善的解释, 而不是泛化为答案生成能力的全面提升。

6.5 答案支持分析

PubMedQA 答案选择分析进一步区分了证据检索与答案正确性。对于 Hybrid 和 HGB 的 top 10 证据, 规则化引用支持率均为 1.0000, 因为每个评估问题都至少检索到一个金标准证据段落。然而, 答案支持率仍受轻量 yes/no/maybe 答案选择器限制: 多数类基线的支持答案比例为 0.5550, 而 TF-IDF 逻辑回归在 Hybrid 与 HGB top 10 上分别为 0.5050 和 0.4800。在 98 个抽取到问题实体的问题中, top 10 答案-证据实体一致性为 0.5510。这些分析使用 qrels、金标准标签和确定性实体重叠, 而不是 LLM 评审。因此, 在加入更强答案与忠实性建模前, 答案生成仍应作为次要任务。

表 8 报告受控 Qwen3-8B pilot。在 100 个 PubMedQA 问题上, 相对于 Hybrid RRF 证据, KCH 风格超图证据在相同 prompt 和解码设置下将答案准确率从 0.3400 提高到 0.3700, 将 Macro-F1 从 0.3506 提高到 0.3760。三个证据来源的引用支持率均为 0.9900, 因此该 pilot 未显示引用支持差异; 主要结论是证据排序可能影响下游标签选择。由于 PubMedQA cross-encoder 条件使用的是当前可用的语义 cross-encoder 输出, 而不是已完成的 MedCPT PubMedQA 复现实验, 该结果被报告为诊断性 RAG 闭环, 而不是完整第二数据集主张。

表 8: PubMedQA Qwen3-8B 下游生成 pilot, 样本为 100 个问题。所有方法使用相同 prompt、top-5 证据、temperature 0, 且不进行微调。PubMedQA cross-encoder 条件使用当前可用的语义 cross-encoder 输出, 不等同于已完成的 MedCPT PubMedQA 实验。

证据来源 + LLM	Accuracy	Macro-F1	引用支持	无支持声明	实体一致性
Hybrid RRF + Qwen3-8B	0.3400	0.3506	0.9900	0.0100	0.5594
语义 cross-encoder + Qwen3-8B	0.3400	0.3504	0.9900	0.0100	0.5782
KCH 风格超图重排序 + Qwen3-8B	0.3700	0.3760	0.9900	0.0100	0.5751

表 9: 增强 BioASQ 留出测试集消融结果, 差值相对于增强 Hybrid RRF。

方法	Recall@10	MRR@10	nDCG@10	$\Delta R@10$
增强 Hybrid RRF	0.4660	0.7530	0.5844	–
仅检索特征 LambdaMART	0.5208	0.7791	0.6282	+0.0548
LambdaMART + 语义, 无超图	0.5328	0.7885	0.6451	+0.0669
成对图 LTR	0.5292	0.7876	0.6412	+0.0632
无医学知识超图 LTR	0.5266	0.7782	0.6362	+0.0606
完整 KCH-MedRank	0.5332	0.7882	0.6446	+0.0673
移除语义分数	0.5244	0.7790	0.6330	+0.0584
移除 MeSH 层级	0.5355	0.7854	0.6441	+0.0696
移除实体特征	0.5318	0.7893	0.6443	+0.0658
移除超图扩散/中心性	0.5341	0.7872	0.6452	+0.0681
移除 PrimeKG 关系	0.5252	0.7834	0.6375	+0.0592

7 消融实验

消融实验用于区分检索强度、生物医学语义、医学知识约束和超图结构的贡献。评估变体分别移除生物医学语义分数、MeSH 层级特征、生物医学实体特征、超图扩散与中心性、PrimeKG 关系特征。所有变体使用同一增强 top-100 候选池, 因此差异反映重排序行为, 而不是候选可用性。

本文对消融结果保持克制解释。生物医学语义和检索特征很强。MeSH 层级和共享概念簇提供了具有医学可解释性的特征, 但部分 leave-one-out 消融差异较小或呈混合趋势。PrimeKG 精确名称关系特征覆盖较低, 除非后续概念归一化显著提升其贡献, 否则应保持辅助定位。

消融表显示四点。第一, 仅使用检索特征进行学习排序已经相对于增强 Hybrid RRF 带来较强提升, Recall@10 从 0.4660 提高到 0.5208。这说明监督式查询分组排序目标本身是方法的重要组成部分。第二, 加入生物医学语义证据后, 最强重排序变体进一步改善; 不含超图但包含语义特征的模型达到 Recall@10 = 0.5328、MRR@10 = 0.7885。

第三, 图结构和医学约束更适合解释为互补特征。成对图 LTR 与完整 KCH-MedRank 表现接近, 而不含医学知识的超图变体在 Recall@10 和 MRR@10 上弱于完整模型。这支持使用医学约束, 但不应声称单靠超边结构主导提升。第四, PrimeKG 在该实现中不是主要驱动因素。移除

表 10: 增强 BioASQ 留出测试集上, 完整 KCH-MedRank 相对于强消融变体的成对 bootstrap 检验。差值为完整模型减去消融模型, 括号内为 95% 置信区间。

基线消融	$\Delta\text{MRR}@10$	$\Delta\text{Recall}@10$	$\Delta\text{nDCG}@10$
LambdaMART + 语义, 无超图	-0.0003 [-0.0047, 0.0040], $p = 0.8947$	0.0004 [-0.0032, 0.0041], $p = 0.8253$	-0.0005 [-0.0030, 0.0019], $p = 0.6895$
成对图 LTR	0.0006 [-0.0043, 0.0056], $p = 0.7991$	0.0040 [0.0010, 0.0079], $p = 0.0054$	0.0035 [0.0011, 0.0062], $p = 0.0048$
移除 MeSH 层级	0.0028 [-0.0024, 0.0079], $p = 0.2938$	-0.0023 [-0.0075, 0.0026], $p = 0.3562$	0.0006 [-0.0027, 0.0037], $p = 0.7407$
移除超图扩散/中心性	0.0010 [-0.0040, 0.0059], $p = 0.6855$	-0.0009 [-0.0049, 0.0026], $p = 0.6777$	-0.0006 [-0.0030, 0.0018], $p = 0.6421$

表 11: 943 个成对留出测试问题上增强 Hybrid w122 与增强 KCH-MedRank 的 top-10 失败分析。

诊断项	数值
成对问题数	943
救回金标准证据的问题数	414
救回金标准证据段落数	661
丢失金标准证据的问题数	214
丢失金标准证据段落数	307
净救回段落数	+354

PrimeKG 关系特征后模型仍有 $\text{Recall}@10 = 0.5252$ 、 $\text{MRR}@10 = 0.7834$, 这与精确名称关系匹配覆盖稀疏的观察一致。

表 10 进一步给出相对于强消融变体的成对 bootstrap 检验。完整 KCH-MedRank 在 $\text{Recall}@10$ 和 $\text{nDCG}@10$ 上显著优于成对图 LTR, 但相对于 LambdaMART + 语义且无超图、移除 MeSH 层级、移除超图扩散/中心性的差异均未达到统计显著。该结果收窄了可支持的主张: 局部超图和医学知识特征提升了解释性并提供有用信号, 但当前证据不能证明任何单一特征组主导排序收益。

综合来看, 消融结果支持一个组合式框架: 高召回候选生成、生物医学语义重排序特征、监督式 listwise 学习, 以及可解释的局部超图知识特征共同提升证据检索。

8 案例分析

失败分析在 943 个成对 BioASQ 留出测试问题上比较 Enhanced Hybrid w122 与 Enhanced KCH-MedRank 的 top 10 结果。KCH-MedRank 将 661 个金标准证据段落救回 top 10, 同时有 307 个金标准证据段落从 top 10 中丢失。该净收益支持证据检索主张, 但丢失案例同样重要, 因为它们显示知识约束特征有时会压过强词法或语义排序信号。

表 12 展示一个救回案例和一个丢失案例。在 p-crAssphage 救回案例中, 金标准段落从第 54 位提升到第 1 位。主要对齐信号是共享的 bacteriophage 概念, 并由局部 phage 相关候选簇支持。这一模式与方法设计一致: 当初始增强混合排序将医学对齐证据排在 top 10 之外时, MeSH 与局部超图特征可以提升该证据。

ubiquitination 丢失案例则展示相反情形。尽管金标准段落讨论了 mono-ubiquitinated LDH-A 和 poly-ubiquitinated LDH, 其排名仍从第 2 位降至第 18 位。问题与段落包含相关生化术语, 但

表 12: BioASQ 留出测试集中 Enhanced Hybrid w122 与 KCH-MedRank 对比的代表性救回与丢失证据案例。

案例	金标准排名	问题、信号与解释
救回	54 $\rightarrow$ 1	问题: What is the p-crAssphage? 主要信号包括 bacteriophages、crAssphage、viral genome 和 phylogeny。金标准段落与问题共享 bacteriophage 概念, 并连接到局部 phage 相关候选簇, 使重排序器能够恢复增强混合排序遗漏的证据。
丢失	2 $\rightarrow$ 18	问题: Is there any protein that undergoes both mono-ubiquitination and poly-ubiquitination? 主要信号包括 ubiquitin、ubiquitination、ubiquitins 和 post-translational processing。该段落相关, 但使用了相关生化形式和更宽泛的加工概念; 同义词与层级特征未能充分对齐 mono-/poly-ubiquitination 与段落证据。

同义词和层级特征未能充分对齐表面形式及更宽泛的翻译后加工概念。类似丢失还出现在甲状腺激素类似物、cilengitide 受体、dasatinib 治疗、GIST 治疗和 Fanconi anemia 等问题中。这些案例支持后续改进生物学概念归一化, 而不是对关系特征作过强结论。

9 讨论

实验结果支持一个聚焦主张: KCH-MedRank 提供了一个可解释医学证据控制层, 能够相对于强检索和语义重排序基线提升生物学证据检索。相对于真实 MedCPT Cross-Encoder 基线, 统计上最有力的比较是 Recall@10; MRR@10 和 nDCG@10 虽为正向提升, 但未达到显著。因此, 最稳妥的解释是 KCH-MedRank 更擅长把额外相关证据移入 top-10 证据集合, 而不是保证每个问题的一位精度都更高。

消融结果表明, 该方法应被理解为一个组合式生物学重排序框架。检索和语义特征仍然是强贡献因素, 而超图扩散、MeSH 层级、实体重叠和关系特征提供互补信号。这一点具有科学价值, 但也约束了新颖性表述: 本文贡献不是独立的超图公式, 而是一种可复现地将医学知识约束注入查询级重排序的方法。

额外的选择诊断也支持保持这一克制解释。一个补充实验将完整 KCH-MedRank 的验证选择主指标改为 Recall@10, 但其留出测试 Recall@10 为 0.5294, 低于本文报告的以验证 MRR 为主选择的主模型 0.5332。因此, 本文保留原验证选择策略, 而不是在观察留出测试结果后改调目标。该诊断也说明, 单纯改变选择优先级不足以稳定提分; 未来提升更可能来自更好的生物学概念归一化和更稳定的特征组选择。

PubMedQA Qwen3-8B pilot 增加了下游 RAG 系统诊断。在固定证据数量、prompt、模型和解码设置下, KCH 风格超图证据在 100 个 PubMedQA 问题上相对于 Hybrid RRF 证据提高了答案准确率和 Macro-F1。由于所有方法的引用支持率都已较高, 该 pilot 不能被解读为忠实性显著改善的证明; 它表明白盒证据选择可以在不训练或微调大模型的情况下影响下游 medical RAG 答案闭

表 13: 增强 BioASQ 实验的计算 profile。日志记录了规模、特征维度、覆盖率和硬件信息；并未对所有组件提供可靠的端到端 wall-clock 时间。

组件	记录的规模或设置	含义
处理后数据	4,719 个问题；40,221 个段落；42,608 条 qrels	适合可复现的离线重排序实验。
候选池	每个问题 top-100；471,900 条预测记录	重排序受局部候选池约束，而不是受全局语料图约束。
增强 KCH-MedRank 划分	2,832 个训练问题、944 个验证问题、943 个留出测试问题	超参数在留出测试之前完成选择。
特征矩阵	45 个特征；283,200 条训练样本；377,600 条最终训练加验证样本	学习排序保持为查询分组的表格排序问题。
局部超图范围	问题、top-100 段落、文档、实体、MeSH、层级和可选关系节点	传播成本随 top- M 和局部特征覆盖率扩展。
MeSH 覆盖	31,110 个描述符；37,356/40,221 个段落和 4,264/4,719 个问题具有 MeSH 匹配	受控词表特征具有较好覆盖。
PrimeKG 过滤	扫描 8,100,498 行；保留 5,766 条项目局部关系	关系特征较稀疏，应保持辅助定位。
稠密生物学检索	MedCPT dual encoder 在 RTX 4060 Laptop GPU 上使用 CUDA	GPU 加速适合稠密检索。
Cross-Encoder 打分	早期通用 CPU 运行在 2,400 秒后超时；最终 MedCPT Cross-Encoder 测试基线完成 943 个问题和 94,300 个候选打分	完整 Cross-Encoder 重打分明显比表格重排序更昂贵。

环。这强化了将 KCH-MedRank 视为证据控制层的动机，但完整生成评估和 PubMedQA MedCPT 重排序条件仍需后续完成。

仍存在若干限制。第一，方法依赖强候选池；如果 top-100 召回较低，重排序无法恢复缺失证据。第二，PrimeKG 精确名称映射较稀疏，不能过度宣称。第三，强消融 bootstrap 检验显示完整 KCH-MedRank 与若干接近消融之间差异并不显著，因此超图、MeSH 层级、实体和关系信号应被描述为互补且可解释的信号，而不是单独占主导的因素。第四，Qwen3-8B 生成结果是 100 个 PubMedQA 问题的 pilot；在作为中心答案生成主张前，需要扩大规模并补充完整的生物学 cross-encoder 条件。

9.1 计算 Profile

表 13 总结了实验日志中可获得的计算 profile。局部超图只围绕每个问题的 top- M 候选构建，而不是在全局生物学语料上构建，因此图构建和扩散成本随候选池和局部特征覆盖率扩展。在增强 BioASQ 设置中，最终学习排序矩阵包含 45 个特征和 377,600 条训练加验证样本，使重排序

保持在常规表格排序问题范围内。稠密生物医学检索受益于 GPU 加速。Cross-Encoder 重打成本明显更高：早期通用 cross-encoder 的 BioASQ CPU 运行在 2,400 秒后超时，而最终 MedCPT Cross-Encoder 基线需要单独的受控完整测试运行。这些观察支持将 KCH-MedRank 视为实用的离线证据重排序模块；系统性的 wall-clock 和内存基准留待后续工作完成。

未来工作应改进生物医学概念归一化，加强同义词和缩写处理，并在证据支持指标完整后扩大受控答案生成评估。更强的生成实验应衡量引用支持率、无支持声明和答案-证据实体一致性，而不仅是答案准确率。

10 结论

本文提出 KCH-MedRank：一种可解释医学证据控制层，其实现形式是轻量、可复现、知识约束的局部超图学习排序框架。该方法保持第一阶段检索的实用性，围绕问题、段落、文档、实体、MeSH 和关系信号构建局部跨粒度超图，并将医学与结构信号作为可解释的学习排序特征。

BioASQ 结果表明，该方法相对于原始与增强 Hybrid RRF 均取得了更强的 top-10 证据检索效果，并且相对于增强 Hybrid RRF 的多个 top-10 检索指标达到统计显著。在同一增强候选池上，相对于真实 MedCPT Cross-Encoder 基线，最有力的结果是 Recall@10 的显著提升；MRR@10 与 nDCG@10 为正向但未显著的趋势。强消融检验显示，图结构和知识信号与检索、语义学习排序特征互补，而不是单独占主导。

PubMedQA Qwen3-8B pilot 表明，在固定 prompt 和解码设置下，证据排序会影响下游答案选择；KCH 风格证据条件提升了 Accuracy 和 Macro-F1，而各比较证据来源的引用支持率都保持较高。总体而言，结果支持将 KCH-MedRank 作为循证医学问答中的白盒证据选择与 grounding 模块。该方法不应被视为经过临床验证的答案生成或决策支持系统。

参考文献

- [1] Payal Chandak, Kexin Huang, and Marinka Zitnik. Building a knowledge graph to enable precision medicine. *Scientific Data*, 10:67, 2023. doi: 10.1038/s41597-023-01960-3. URL <https://www.nature.com/articles/s41597-023-01960-3>. Accessed 2026-05-21.
- [2] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 758–759. ACM, 2009. doi: 10.1145/1571941.1572114. URL <https://research.google/pubs/reciprocal-rank-fusion-outperforms-condorcet-and-individual-rank-learning-methods/>. Accessed 2026-05-21.
- [3] Darren Edge, Ha Trinh, Newman Cheng, Joshua Bradley, Alex Chao, Apurva Mody, Steven Truitt, and Jonathan Larson. From local to global: A graph RAG approach to query-focused

- summarization. *arXiv preprint arXiv:2404.16130*, 2024. doi: 10.48550/arXiv.2404.16130. URL <https://arxiv.org/abs/2404.16130>. Accessed 2026-05-21.
- [4] Qiao Jin, Bhuwan Dhingra, Zhengping Liu, William Cohen, and Xinghua Lu. PubMedQA: A dataset for biomedical research question answering. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 2567–2577. Association for Computational Linguistics, 2019. doi: 10.18653/v1/D19-1259. URL <https://aclanthology.org/D19-1259/>. Accessed 2026-05-21.
- [5] Qiao Jin, Won Kim, Qingyu Chen, Donald C. Comeau, Lana Yeganova, W. John Wilbur, and Zhiyong Lu. Medcpt: Contrastive pre-trained transformers with large-scale pubmed search logs for zero-shot biomedical information retrieval. *arXiv preprint arXiv:2307.00589*, 2023. doi: 10.48550/arXiv.2307.00589. URL <https://arxiv.org/abs/2307.00589>. Accessed 2026-05-21.
- [6] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems 30*, 2017. URL <https://proceedings.neurips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html>. Accessed 2026-05-21.
- [7] Anastasia Krithara, Anastasios Nentidis, Konstantinos Bougiatiotis, and Georgios Paliouras. BioASQ-QA: A manually curated corpus for biomedical question answering. *Scientific Data*, 10(1):170, 2023. doi: 10.1038/s41597-023-02068-4. URL <https://pubmed.ncbi.nlm.nih.gov/36973320/>. Accessed 2026-05-21.
- [8] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Kuttler, Mike Lewis, Wen-tau Yih, Tim Rocktaschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. *arXiv preprint arXiv:2005.11401*, 2020. doi: 10.48550/arXiv.2005.11401. URL <https://arxiv.org/abs/2005.11401>. Accessed 2026-05-21.
- [9] Haoran Luo, Haihong E, Guanting Chen, Yandan Zheng, Xiaobao Wu, Yikai Guo, Qika Lin, Yu Feng, Zemin Kuang, Meina Song, Yifan Zhu, and Luu Anh Tuan. HyperGraphRAG: Retrieval-augmented generation via hypergraph-structured knowledge representation. *arXiv preprint arXiv:2503.21322*, 2025. doi: 10.48550/arXiv.2503.21322. URL <https://arxiv.org/abs/2503.21322>. Accessed 2026-05-21.
- [10] National Library of Medicine. Medical subject headings (MeSH). <https://www.nlm.nih>.

- gov/mesh/meshhome.html, 2026. URL <https://www.nlm.nih.gov/mesh/meshhome.html>. Accessed 2026-05-21.
- [11] Stephen E. Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009. doi: 10.1561/15000000019. URL https://ir.webis.de/anthology/2009.ftir_journal-ir0anthology0volumeA3A4.0/. Accessed 2026-05-21.
- [12] George Tsatsaronis, Georgios Balikas, Prodromos Malakasiotis, Ioannis Partalas, Matthias Zschunke, Michael R. Alvers, Dirk Weissenborn, Anastasia Krithara, Sergios Petridis, Dimitris Polychronopoulos, Yannis Almirantis, John Pavlopoulos, Nicolas Baskiotis, Patrick Gallinari, Thierry Artieres, Axel-Cyrille Ngonga Ngomo, Norman Heino, Eric Gaussier, Laura Barrio-Alvers, Michael Schroeder, Ion Androutsopoulos, and Georgios Paliouras. An overview of the BIOASQ large-scale biomedical semantic indexing and question answering competition. *BMC Bioinformatics*, 16:138, 2015. doi: 10.1186/s12859-015-0564-6. URL <https://link.springer.com/article/10.1186/s12859-015-0564-6>. Accessed 2026-05-21.
- [13] Changjian Wang, Weihong Deng, Weili Guan, Quan Lu, and Ning Jiang. Cross-granularity hypergraph retrieval-augmented generation for multi-hop question answering. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2026. URL <https://ojs.aaai.org/index.php/AAAI/article/download/40623/44584>. Accessed 2026-05-21.
- [14] Junde Wu, Jiayuan Zhu, Yunli Qi, Jingkun Chen, Min Xu, Filippo Menolascina, and Vicente Grau. Medical graph RAG: Towards safe medical large language model via graph retrieval-augmented generation. *arXiv preprint arXiv:2408.04187*, 2024. doi: 10.48550/arXiv.2408.04187. URL <https://arxiv.org/abs/2408.04187>. Accessed 2026-05-21.
- [15] Guangzhi Xiong, Qiao Jin, Zhiyong Lu, and Aidong Zhang. Benchmarking retrieval-augmented generation for medicine. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 6233–6251. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.findings-acl.372. URL <https://aclanthology.org/2024.findings-acl.372/>. Accessed 2026-05-21.
- [16] Guangzhi Xiong, Qiao Jin, Xiao Wang, Minjia Zhang, Zhiyong Lu, and Aidong Zhang. Improving retrieval-augmented generation in medicine with iterative follow-up questions. *arXiv preprint arXiv:2408.00727*, 2024. doi: 10.48550/arXiv.2408.00727. URL <https://arxiv.org/abs/2408.00727>. Accessed 2026-05-21.
- [17] Fangfang Xu, Yifan Kuai, Chao Gao, Dan Luo, and Jinguang Gu. Medical HyperRAG: A hypergraph-enhanced retrieval-augmented generation framework for clinical question an-

swering. *Research Square preprint*, 2026. doi: 10.21203/rs.3.rs-8497459/v1. URL <https://doi.org/10.21203/rs.3.rs-8497459/v1>. Accessed 2026-05-21.